3D CNN 기반 도심 3 차원 데이터 의미론적 분할을 위한 복셀라이제이션 기법별 성능 비교

김재홍 [1,4], 서재석 [2,4], 박기욱 [3,4], 이유진 [4], 김광수 [4], 이기훈 [4]*
동국대학교 [1], 건양대학교 [2], 울산대학교 [3], 한국전자통신연구원 [4]*

imjahk@dgu.ac.kr, vhvj1398@gmail.com, kmj977284@gmail.com, {yu_jin, enoch, *hoony}@etri.re.kr

3D CNN-Based Semantic Segmentation of Urban Data: A Performance Comparison of Voxelization Techniques

Kim Jaehong[1,4], Seo Jaeseok[2,4], Park Kiwook[3,4], Lee Yujin[4,] Kim Kwangsoo[4], Lee Kihoon[4]
Dongguk Univ[1]., Konyang Univ[2]., Ulsan Univ[3]., ETRI[4]

요 약

본 연구에서는 도시 3 차원 Point Cloud 의 의미론적 분할을 위해 복셀 데이터의 색상 표현과 공간 구성 방식에 따른 성능을 비교·분석하였다. Point Cloud 로 구성된 STPLS3D 데이터를 0.3 m 크기의 voxel 로 변환하고, RGB 평균값과 지배적인 색상정보를 활용하는 RGB-16, Z 축 전체 높이 정보를 유지하는 Full-Z 방식을 구성하였다. 이를 기반으로 Baseline, RGB-16, Full-Z, Full-Z+ RGB-16 을 동일한 Sparse 3D CNN 에 적용하였다. 실험 결과, Z 축 전체 높이 정보와 지배적인 색상정보를 함께 활용한 Full-Z+ RGB-16 이 가장 우수한 의미론적 분할 성능을 나타냈으며, 복셀 내부의 색상 및 공간정보 구성 방식이 3D CNN 성능에 중요한 영향을 미침을 확인하였다.

Ⅰ. 서 론

전 세계적으로 도시화와 도시공간의 디지털 전환이 지속됨에 따라 효율적인 도시계획·관리와 3D 공간정보 구축의 필요성이 증가하고 있다[1]. 복잡한 도시공간을 효과적으로 분석하기 위해 건물, 도로, 수목 및 시설물과 같은 도시 객체를 자동으로 식별하는 의미론적 분할이 활발하게 활용되고 있다[2]. 도시공간을 표현하는 Point Cloud 는 실제 형상을 정밀하게 표현할 수 있었으나 비정형 구조와 불균일한 점 밀도로 인해 데이터 처리에 제약이 존재하고 있다[3]. Voxelization 과정을 통해 이러한 Point Cloud 를 규칙적인 3D 격자로 변환하여 건물, 수목, 지형 등 다양한 도시정보를 통합적으로 표현하고 분석하는 데 활용되어 왔다 [4]. 이러한 배경에서 본 연구에서는 Point Cloud 로 구축된 3D 도심데이터를 복셀화하고 sparse 3D CNN 을 적용하고자 한다. 또한, 효율적인 데이터셋 구축 및 입력 방식에 따른 성능을 분석하고 실무 적용 가능성을 논하고자 한다.

Ⅱ. 본론

본 연구에서는 도시 3D 공간의 의미론적 분할을 위해 STPLS3D 데이터셋을 활용하였다. 학습 및 검증에는 Synthetic_v1, v2, v3 를, 실제 환경에서의 일반화 성능 평가는 RealWorldData 의 WMSC_points 를 사용하였다. Point Cloud 는 0.3 m 크기의 정육면체 voxel 로 변환하였으며, voxel 의 semantic label 은 내부 point 의 Majority Voting 으로 결정하였다. 동률일 경우 voxel 중심에 가장 가까운 point 의 class 를 적용하였다. 또한 합성·실세계 데이터 간 동일한 학습 체계를 구성하기 위해 세부 class 를 Ground, Building, Tree, Car, Light pole, Fence 의 6 개 Common Class 로 통합하였다[2].

Table. 1 Raw classes grouped into the class

Class	Detailed
Ground	0 Ground, 15 Road, 18 Dirt, 19 Grass
Building	1 Building, 7 Aircraft, 9 Bike, 10 Motorcycle; 13 Clutter, 17 Window
Tree	2 Low vegetation, 3 Medium vegetation, 4 High vegetation
Car	5 Vehicle, 6 Truck, 8 Military vehicle
Light pole	11 Light pole, 12 Street sign
Fence	14 Fence

복셀 내부의 색상 표현과 공간 구성 방식에 따른 성능 변화를 분석하기 위해 Baseline, RGB-16, Full-Z, Full-Z+ RGB-16 의 네 가지 입력 방식을 설계하였다. Baseline 은 복셀 내 포인트들의 평균 RGB 를 대표 색상으로 정의하고, X·Y·Z 3 차원 축을 동일한 크기의 정육면체 패치로 분할하였다. RGB-16 의 경우, 각 RGB 채널을 16 단위의 16 개 구간으로 분할하여 총 4,096 개의 색상 bin 을 생성하였다. 이후 복셀 내에서 가장 높은 빈도를 보인 mode bin 에 속한 포인트들의 평균 RGB 를 대표값으로 할당하였다.

Full-Z 는 평균 RGB 를 입력값으로 사용하되, X·Y 방향만 일정 크기의 패치로 분할하고 Z 축의 occupied voxel 전체 높이 정보를 유지하도록 구성하였다. Full-

Z+RGB-16 은 이 두 방식의 장점을 결합하여 학습에 적용하였다. 모델로는 Sparse 3D CNN 을 사용하여 occupied voxel 의 공간 좌표와 RGB 특징을 입력하였으며, 데이터 불균형 문제를 완화하기 위해 손실함수에 클래스별 가중치를 부여하였다. 이를 통해 동일한 네트워크 구조 하에서 복셀 입력 방식에 따른 의미론적 분할 성능 차이를 객관적으로 비교·분석하였다.

Table. 2 Segmentation performance comparison of each patch size

Method	Patch Size (ea)	OA(%)	mIoU(%)	Macro F1(%)
Baseline	32	80.82	39.39	51.72
	64	83.17	44.35	57.61
	128	79.80	46.35	59.75
RGB-16	32	78.39	42.62	56.86
	64	83.84	43.86	56.87
	128	82.55	47.73	61.09
Full-Z	32	76.93	43.13	57.36
	64	**86.50**	47.62	59.90
	128	85.47	45.51	57.61
Full-Z + RGB-16	32	85.34	**48.86**	**61.20**
	64	82.94	47.20	60.54
	128	83.08	47.65	60.81

Full-Z+RGB-16 은 Z 축 전체 높이 정보와 복셀 내부의 지배적인 색상 정보를 동시에 활용하도록 구성되었으며, 패치 크기 32 에서 mIoU 48.86%, Macro F1 61.20%로 전체 실험 중 가장 높은 성능을 기록하였다. 이는 Full-Z 기법을 통해 객체의 수직적 연속성과 높이 정보를 온전히 보존하고, RGB-16 기법을 통해 단순 평균화로 손실될 수 있는 고유 색상 특징을 효과적으로 보완했기 때문이다. 특히 두 정보를 결합함으로써 좁은 X·Y 범위에서도 공간 및 색상 특징을 충분히 확보할 수 있어, 단일 복셀 표현 방식 대비 의미론적 분할 성능 향상에 효과적임을 확인하였다.

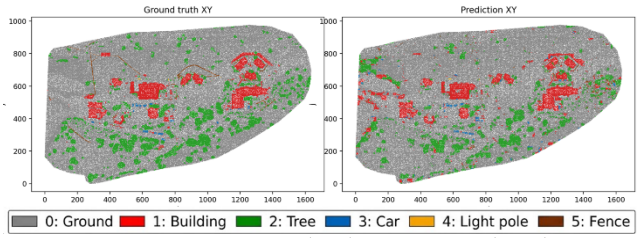


Figure 1. Ground truth(Left) vs. Prediction(Right)

Fig. 1 의 분할 결과를 살펴보면, 지형과 건물 등 대형 객체는 Z 축 높이 정보와 정밀한 색상 특징이 효과적으로 반영되어 우수한 분할 성능과 뚜렷한 경계를 보였다. 그러나 데이터 비중이 적고 기하학적 형태가 복잡한 차량, 울타리 등 소형 객체에서는 오분류로 인해 상대적으로 낮은 수치를 기록하였다. 이는 공간 점유율이 낮은 객체에 대한 클래스 불균형 해소와 추가적인 데이터 정밀화가 요구됨을 보여준다.

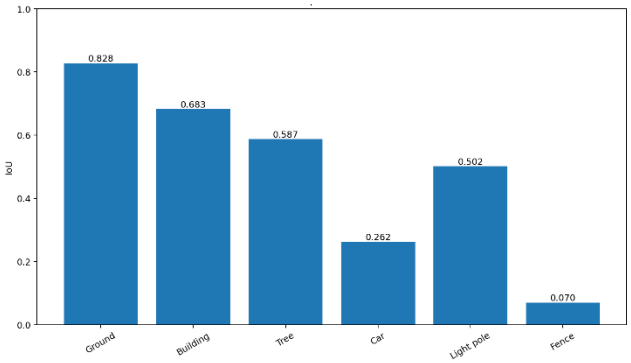


Figure 2. Test per-class IoU

Ⅲ. 결론

Full-Z+RGB-16 은 패치 크기 32 에서 가장 높은 mIoU 와 Macro F1 을 기록하였다. 다만 지표와 패치 크기에 따라 성능 순위가 달라, 입력 요소별 기여와 오류 원인에 대한 추가 분석이 필요하다.

향후 연구에서는 동일한 패치 크기에서 색상·높이 정보 구성에 따른 클래스별 IoU 를 비교하고, 혼동행렬과 오분류 영역을 통해 객체 경계 및 점 밀도에 따른 오류 특성을 분석하고자 한다. 또한 반복 실험과 실세계 데이터 평가를 통해 일반화 성능을 검토하고, 연산 비용을 함께 비교하여 입력 조건별 복셀화 기법의 선택 근거를 마련하고자 한다.

ACKNOWLEDGMENT

본 연구는 국토교통부와 국토교통과학기술진흥원의 지원으로 수행되었음(RS-2025-02317649, 국토정보 고도화를 위한 입체격자체계 적용 및 활용 기술개발)

참 고 문 헌

[1] United Nations, “World Urbanization Prospects 2025: Summary of Results,” United Nations Department of Economic and Social Affairs, Population Division, 124 p., 2025.

[2] M. Chen, Q. Hu, Z. Yu, H. Thomas, A. Feng, Y. Hou, K. McCullough, F. Ren, and L. Soibelman, “STPLS3D: A Large-Scale Synthetic and Real Aerial Photogrammetry 3D Point Cloud Dataset,” Proceedings of the 33rd British Machine Vision Conference (BMVC), Paper 429, 2022.

[3] C. R. Qi, L. Yi, H. Su, and L. J. Guibas, “PointNet++: Deep Hierarchical Feature Learning on Point Sets in a Metric Space,” Advances in Neural Information Processing Systems, vol. 30, pp. 5099-5108, 2017.

[4] K. Fujiwara, R. Tsurumi, T. Kiyono, Z. Fan, X. Liang, B. Lei, W. Yap, K. Ito, and F. Biljecki, “VoxCity: A seamless framework for open geospatial data integration, grid-based semantic 3D city model generation, and urban environment simulation,” Computers, Environment and Urban Systems, vol. 123, Art. no. 102366, 2026.