3D CNN 기반

도심 3차원 데이터의 의미론적 분할을 위한 복셀화 기법별 성능 비교

The 7th Korea Artificial Intelligence Conference

김재홍 서재석 박기욱 이유진 김광수 이기훈

연구 배경 : 머신리더블 데이터 구축을 위한 3차원 공간정보의 구조화

객체의 종류에 따른 입체적 이동 가능 공간과 회피 대상 등의 의미론적 구분

적용 분야



UAM

건물·수목·지면 식별

회피 대상·착륙 후보 판단



실내 로봇

바닥·벽·사람 식별

통행 공간·회피 대상 판단



자율주행차

도로·보행자·차량 식별

주행 영역·회피 대상 판단

LiDAR · SLAM

연구 범위

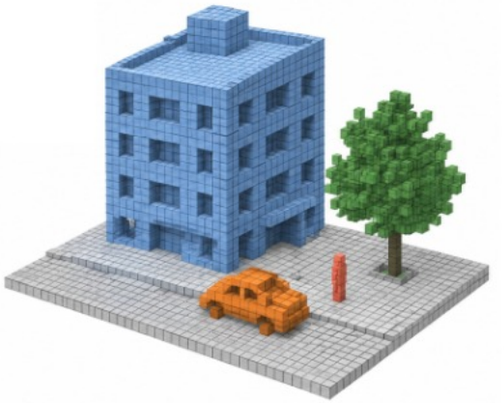
포인트 클라우드



불규칙한 점 분포·밀도
이웃 관계 별도 탐색

AI
복셀화 +
의미 분할

시멘틱 복셀



격자별 점유·클래스 저장
규칙적 이웃·학습 입력

공간 구조와 객체 의미를 함께 반영한 복셀 학습 데이터 구축

복셀화와 의미 분할을 결합해 격자별 시멘틱 구성 → 각 도메인의 판단 입력으로 활용

연구 목적

포인트 클라우드를 의미 정보가 포함된 3차원 시멘틱 복셀 맵으로 변환

01 포인트 클라우드



의미 정보가 없는
3D 점 집합

복셀화
·
라벨링

02 시멘틱 객체



Building
건물



Car
자동차



Tree
나무



Pole
가로등



Ground
지면

...

03 시멘틱 복셀 도시 장면



각 복셀이 객체의 의미 정보를 가짐
(건물, 자동차, 나무, 사람, 지면 등)

04 3D CNN

AI 학습

시멘틱 복셀 데이터를
이용하여 학습

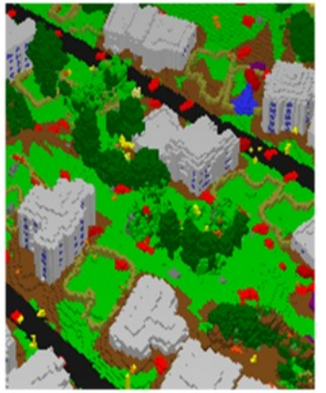
객체 판단

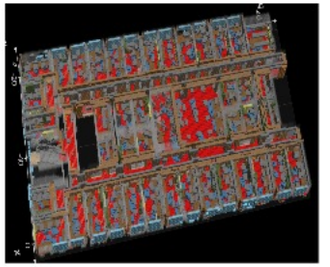
새로운 환경에서 객체를
인식하고 분류

복셀 맵 구축

의미 정보가 포함된
3차원 복셀 맵 생성

05 시멘틱 복셀 맵



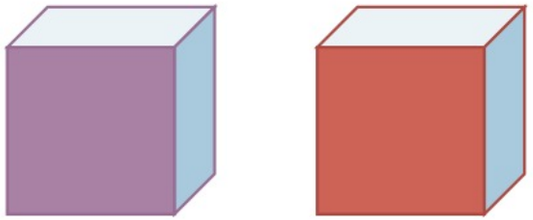


의미 정보가 포함된
3차원 복셀 맵

연구 방법

복셀 구조 학습에 적합한 데이터 구축 방식의 비교

색상 대표값



Mean RGB

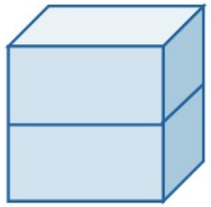
전체 평균

RGB-16

선택 구간 평균

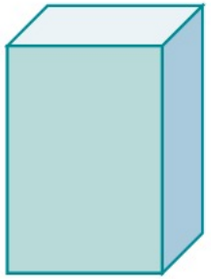
×

공간 구성



Cube

Z축 분할



Full-Z

전체 높이

×

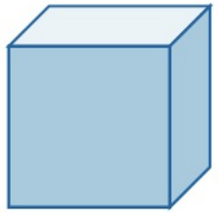
패치 크기



32



64



128

XY 격자 수 P

12개 입력 조건 → **동일 Sparse 3D CNN** → **도시 객체 분할 평가**

색상과 공간 범위의 구성에 따른 분할 성능 차이 분석

실험 순서

01	데이터 구성	합성 장면은 학습·검증, 실제 장면은 평가에 사용
02	복셀 데이터 구축	0.3 m 복셀에 좌표·색상·정답 라벨을 정리
03	입력 구성별 학습 방법	색상 2종, 공간 구성 2종, 패치 크기 3종 비교
04	실제 장면 평가	복셀별 예측을 원래 위치에 모아 정답과 비교

01. 데이터 구성

STPLS3D 합성 장면의 학습·검증과 실제 WMSC_points 장면의 평가



실제 평가 장면: WMSC_points

Synthetic v1~v3

50

학습 장면

13

검증 장면

실제 WMSC 1개 장면 평가

점유 복셀 2,139,806개

6개 클래스
Ground, Building, Tree,
Car, Light pole, Fence

02. 복셀 데이터 구축 - 정답 라벨과 클래스 통합

원본 클래스 투표를 먼저 수행한 뒤 공통 6개 클래스로 매핑

정답 라벨 결정

1 복셀 내부의 원본 클래스 빈도 집계
2 동률 클래스의 점 중
중심에 가장 가까운 점의 라벨 선택
3 선택한 클래스를 Common-6로 통합

순서에 따른 차이: 설명용 예시

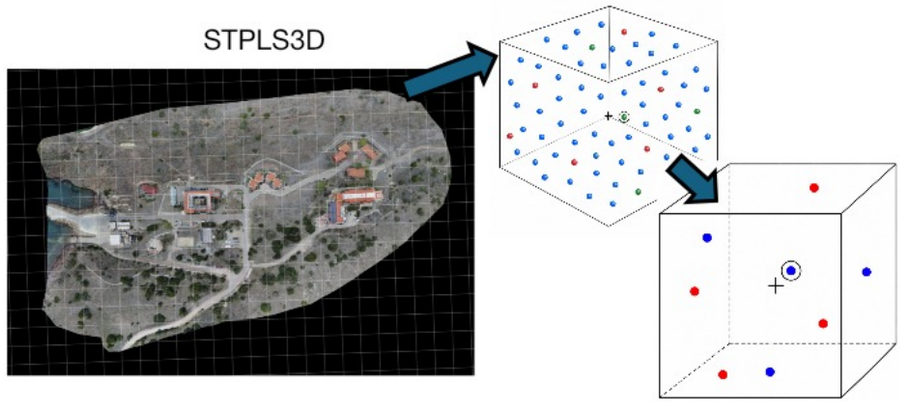
Building 4표, Low veg. 3표, High veg. 3표

원본 클래스 투표 후 통합: Building
먼저 통합하면 Tree 6표로 결과가 달라짐

Common-6	원본 클래스 통합
Ground	Ground / Road / Dirt / Grass
Building	건물 및 인공 구조물
Tree	Low / Medium / High vegetation
Car	Vehicle / Truck / Military vehicle
Light pole	Light pole / Street sign
Fence	Fence

02. 복셀 데이터 구축 - 공통 복셀화 규칙

모든 조건에서 복셀 크기와 정답 라벨 결정 방법을 동일하게 적용



- **Voxel size** — 0.3 × 0.3 × 0.3 m
- **Storage** — Occupied voxels only
- **Feature** — Occ + RGB + NormXYZ (7 ch)
- **Voxel label** — Majority voting
- **Class mapping** — 19 classes → 6 classes

점이 들어 있는 복셀만 저장

빈 격자를 제외한 복셀 좌표·속성 저장

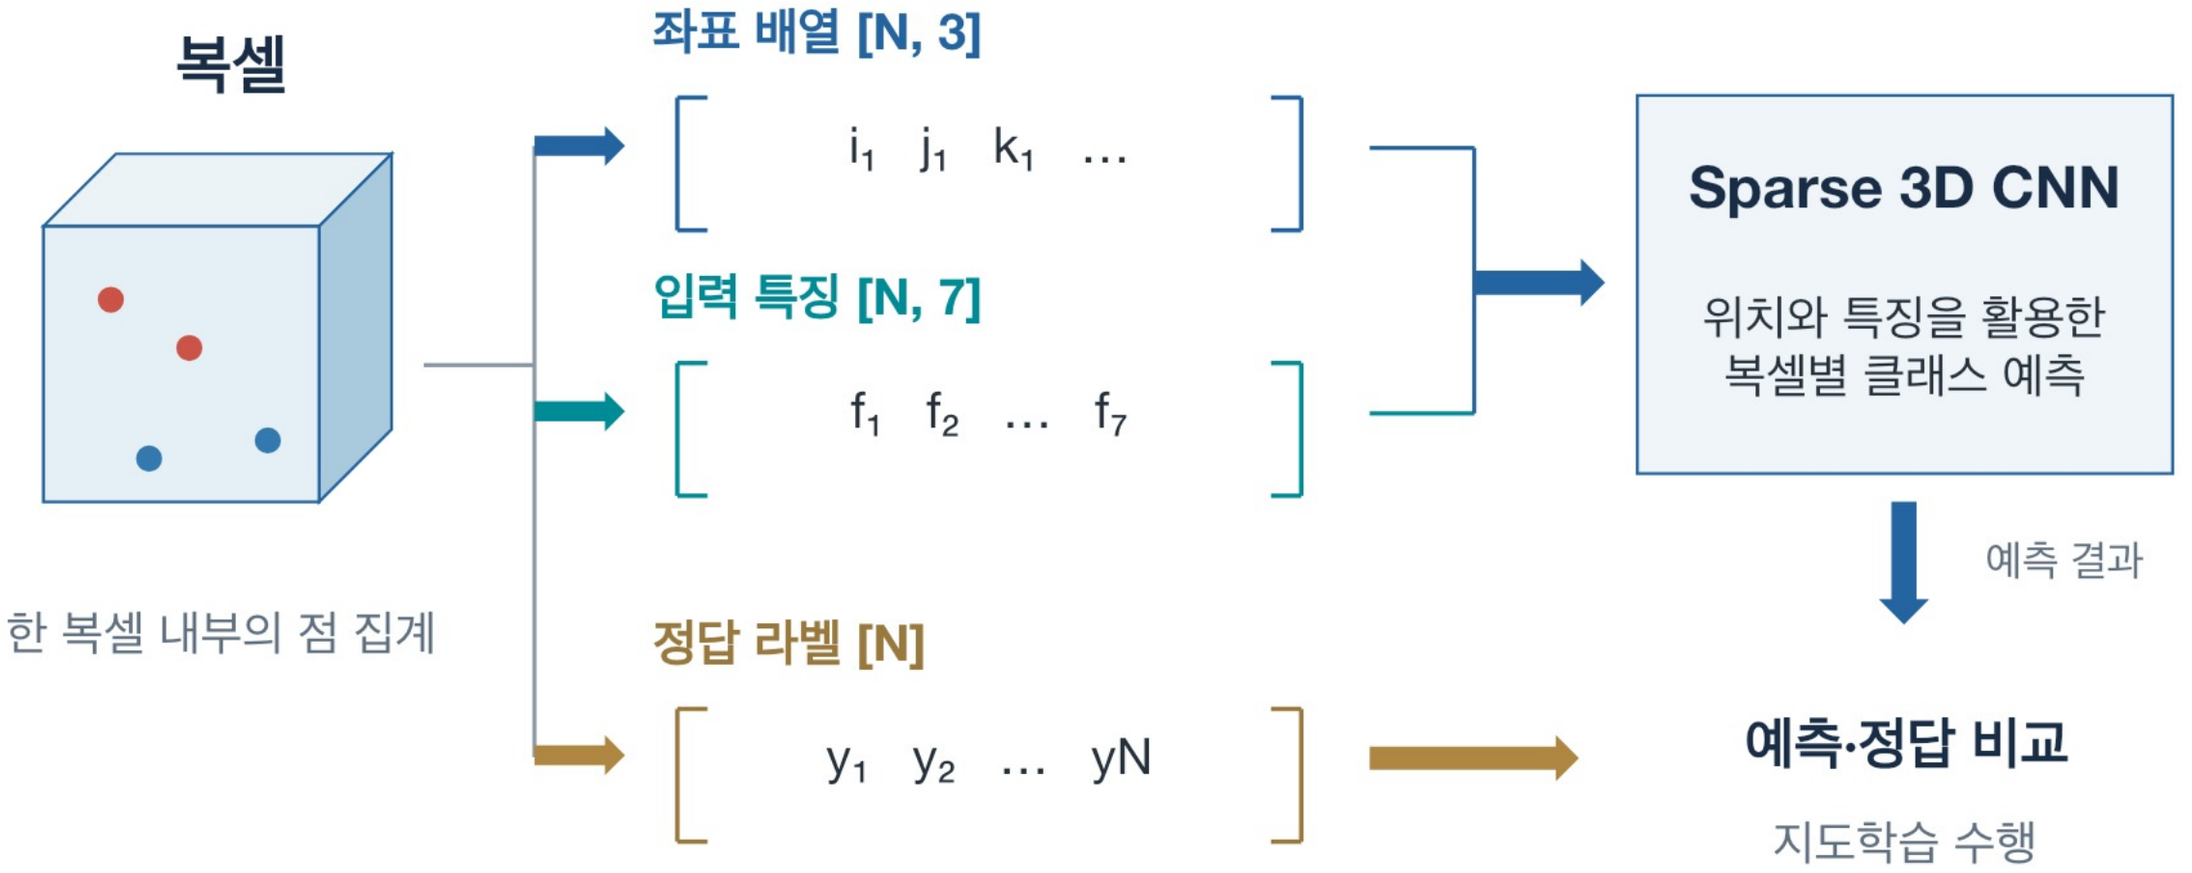
복셀별 정답 라벨 부여

원본 클래스의 최다득표로 정답 선정 후
6개 공통 클래스로 통합

패치가 커져도 복셀 해상도는 0.3 m로 유지

02. 복셀 데이터 구축 - 학습 데이터의 구성

복셀 정보를 모델 입력 배열과 정답 라벨로 구조화



N: 점유 복셀 수. 색상 대표값과 입력 공간 범위의 구성에 따른 학습 정보 차이

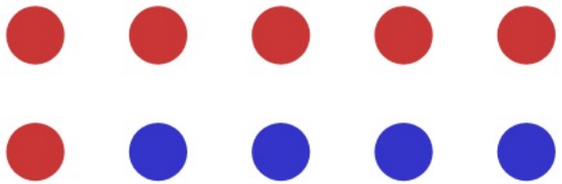
02. 복셀 데이터 구축 - 색상 대표값: 평균 RGB와 RGB-16

가장 많은 점이 속한 색상 구간의 원본 RGB 평균 산출

R·G·B 각각 16개 구간 **16 × 16 × 16 = 4,096개 RGB 조합**

구간 폭 16: 0~15, 16~31, …, 240~255

한 복셀 안의 점: 설명용 예시



구간 A: (12, 3, 3), 6개
원본 평균 (202, 54, 54)

구간 B: (3, 3, 12), 4개
원본 평균 (52, 52, 202)

전체 점의 RGB 평균

(142, 53.2, 113.2)

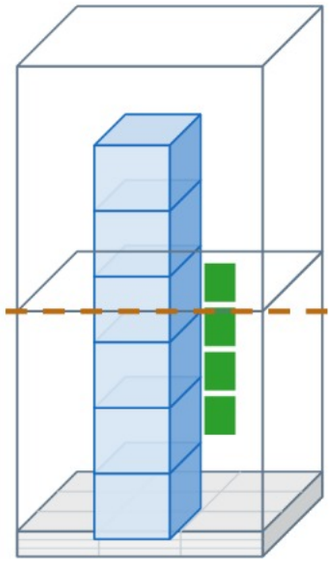
RGB-16: 선택 구간만 평균

(202, 54, 54)

02. 복셀 데이터 구축 - 공간 구성: Cube와 Full-Z

같은 XY 범위에서 높이를 나누어 입력할지, 함께 입력할지 비교

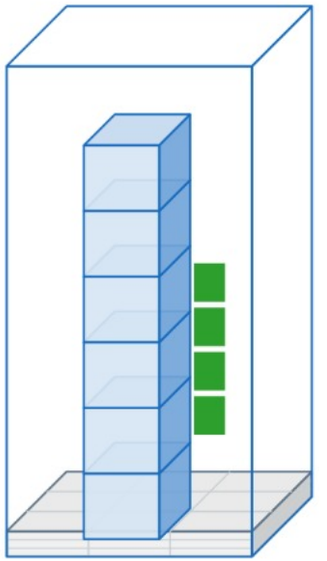
Cube



P × P × P

X·Y·Z를 같은 길이로 잘라 입력

Full-Z



P × P × Hs

X·Y를 자르고 장면의 전체 높이를 포함

Hs: 장면의 점유 복셀 높이 범위. 빈 복셀은 입력에서 제외

03. 입력 구성별 학습 방법

색상 2종과 공간 구성 2종을 조합하고, 각 조합에 패치 크기 3종 적용

입력 방식	색상 대표값	공간 구성
Baseline	전체 점의 RGB 평균	Cube
RGB-16	주요 색상 구간의 RGB 평균	Cube
Full-Z	전체 점의 RGB 평균	전체 높이 포함
Full-Z+RGB-16	주요 색상 구간의 RGB 평균	전체 높이 포함

패치 크기 P	32	64	128
XY 한 변의 길이	9.6 m	19.2 m	38.4 m

총 12개 조건. 복셀 해상도·모델·최대 epoch 공통 적용, stride = P

03. 입력 구성별 학습 방법 - 공통 모델과 학습 설정

Sparse 3D CNN	구성
입력 / 출력	7개 입력 채널 / 6개 클래스
Encoder 채널	16, 32, 64, 128
기본 블록	SubM 3×3×3, residual block
문맥 특징	ASPP d=1/2/4, patch global context
Decoder	Upsampling과 skip 연결
학습 파라미터 수	4,496,467

Main loss = 0.50 Weighted CE + 0.30 Lovasz-Softmax + 0.20 Dice

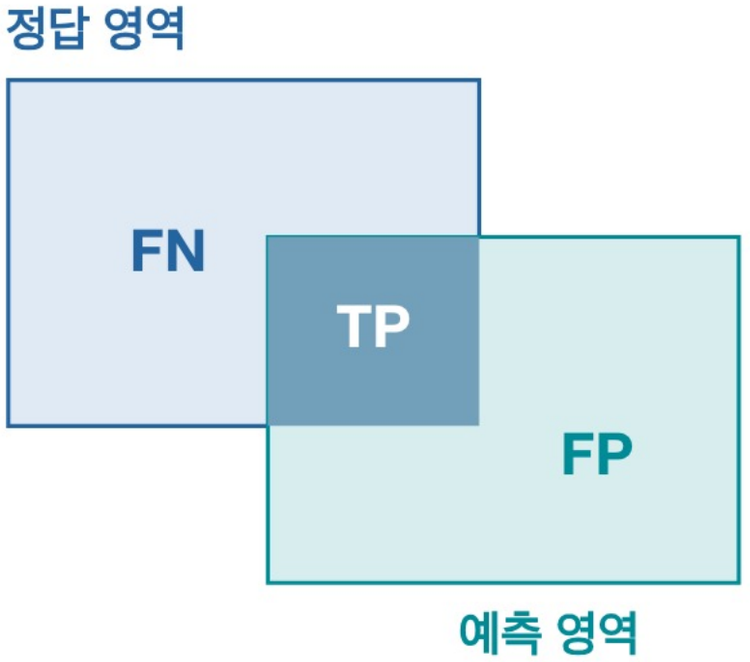
보조 semantic head와 boundary head의 loss를 추가 적용

학습 항목	설정
GPU	RTX 5090 1대
Framework	PyTorch / Native sparse
Batch / 최대 epoch	24 / 35
Optimizer / 초기 LR	AdamW / 0.002
Weight decay	0.0001
Scheduler	CosineAnnealingLR
정밀도	FP16 AMP, sparse 누적 FP32
체크포인트 선택	검증 mIoU 최고값

04. 실제 장면 평가 - 평가 방법과 지표

실제 장면의 점유 복셀을 기준으로 예측과 정답의 비교 수행

한 클래스의 정답·예측 비교



IoU = TP / (TP + FP + FN)

Coverage 100%: 평가 대상 복셀 전체에 대한 예측 완료

mIoU

6개 클래스 IoU의 평균
각 클래스를 같은 비중으로 평가

Accuracy

전체 복셀 중 정답 비율

Macro F1

클래스별 정밀도·재현율의 조화평균 후
6개 클래스의 평균 산출

04. 실제 장면 평가 - 전체 정량 평가 결과

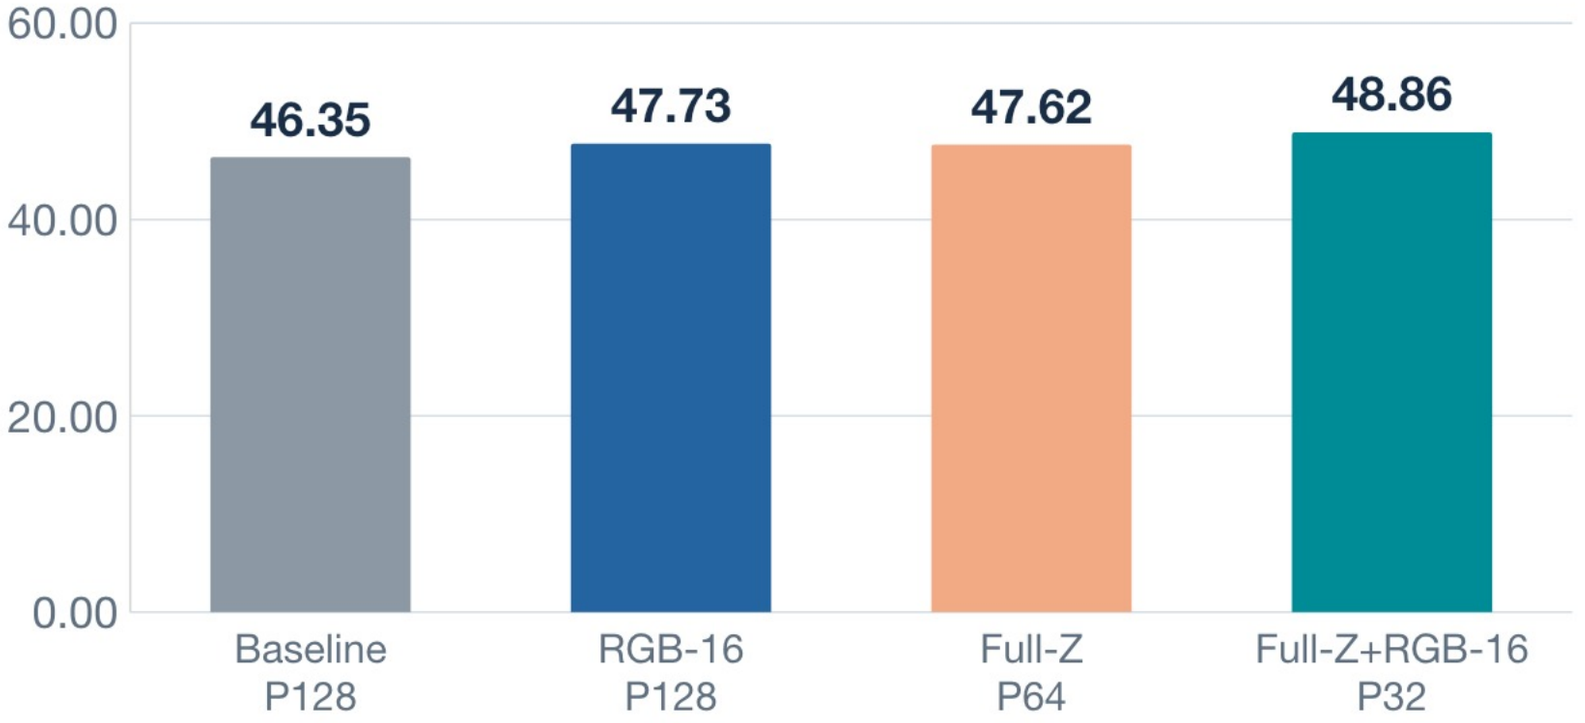
WMSC_points / Common-6 / 단위 %

입력 방식	P	Accuracy	mIoU	Macro F1
Baseline	32	80.82	39.39	51.72
Baseline	64	83.17	44.35	57.61
Baseline	128	79.80	46.35	59.75
RGB-16	32	78.39	42.62	56.86
RGB-16	64	83.84	43.86	56.87
RGB-16	128	82.55	47.73	61.09
Full-Z	32	76.93	43.13	57.36
Full-Z	64	86.50	47.62	59.90
Full-Z	128	85.47	45.51	57.61
Full-Z+RGB-16	**32**	**85.34**	**48.86**	**61.20**
Full-Z+RGB-16	64	82.94	47.20	60.54
Full-Z+RGB-16	128	83.08	47.65	60.81

Baseline / P32: 일부 epoch의 loss NaN 기록. 최고 Accuracy는 Full-Z / P64.

04. 실제 장면 평가 - 입력 방식별 최고 성능

각 입력 방식의 패치 크기 3종 중 가장 높은 mIoU를 비교 (단위 %)



Full-Z+RGB-16 / P32

mIoU

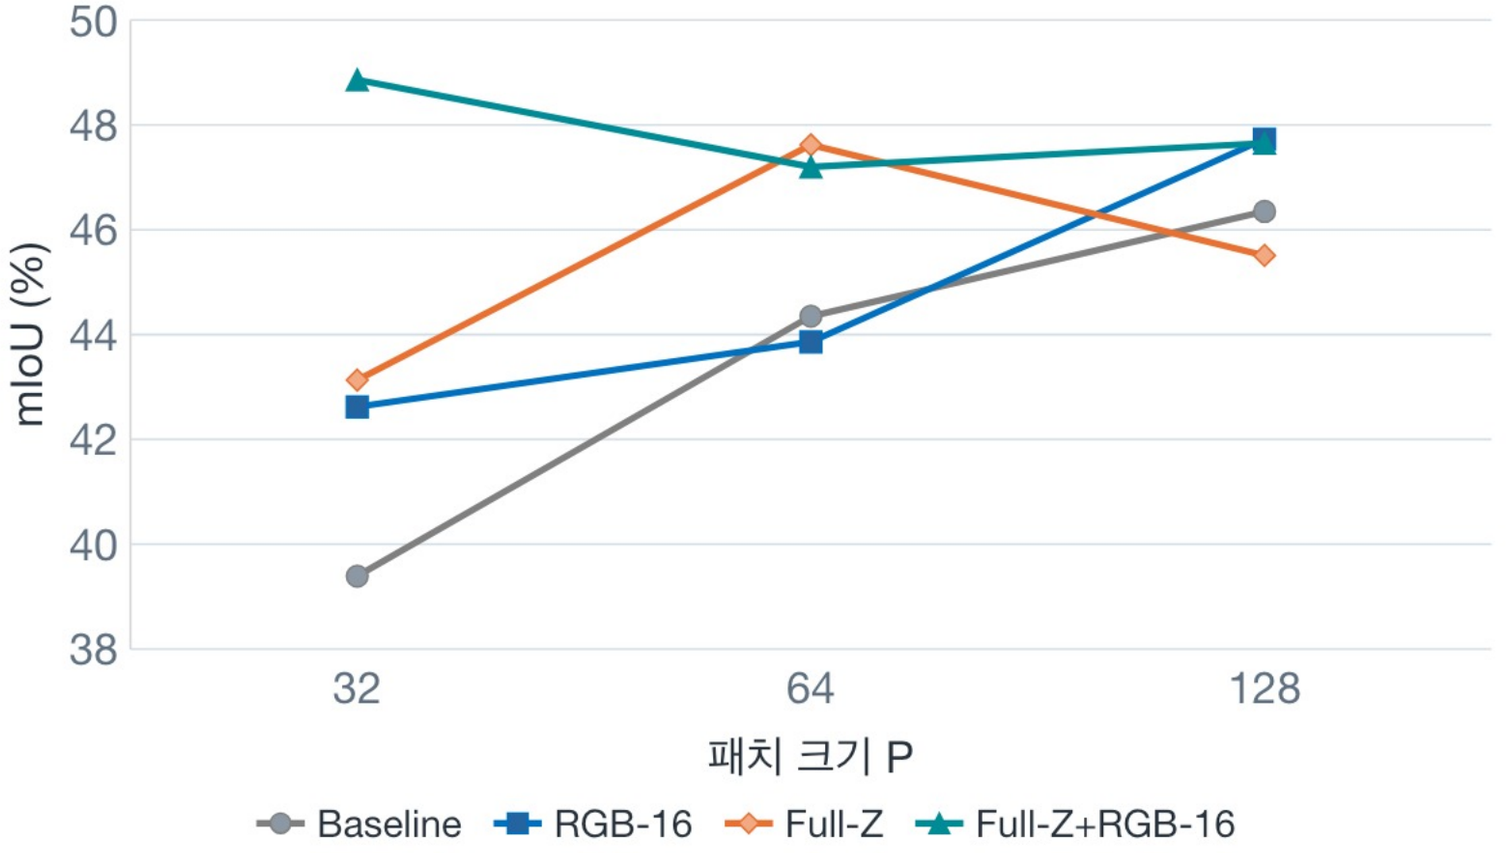
48.86%

Macro F1 61.20%
Accuracy 85.34%

평가 대상 WMSC 1개 장면. 최고 Accuracy 86.50% (Full-Z / P64)

04. 실제 장면 평가 - 패치 크기에 따른 mIoU 비교 분석

입력 구성별 패치 크기 변화에 따른 mIoU 비교



RGB-16 적용 효과

Full-Z / P32

+5.73%p

43.13% → 48.86%

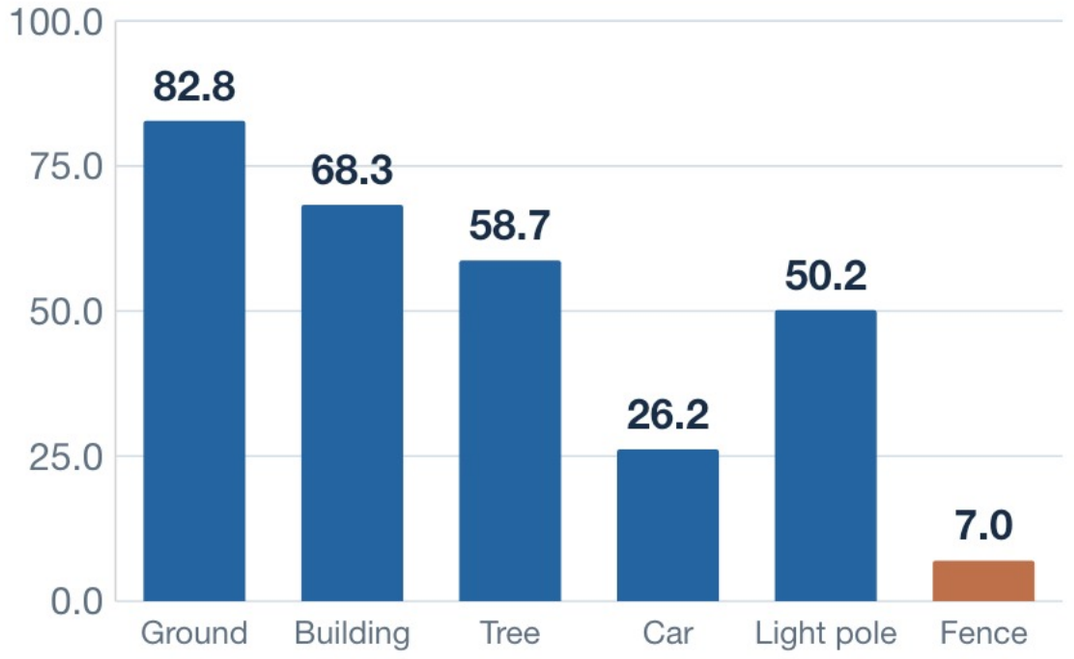
P64에서는 Cube와 Full-Z 모두 mIoU가 소폭 감소

패치 크기와 색상 표현의 조합을 고려한 입력 구성 선택 필요

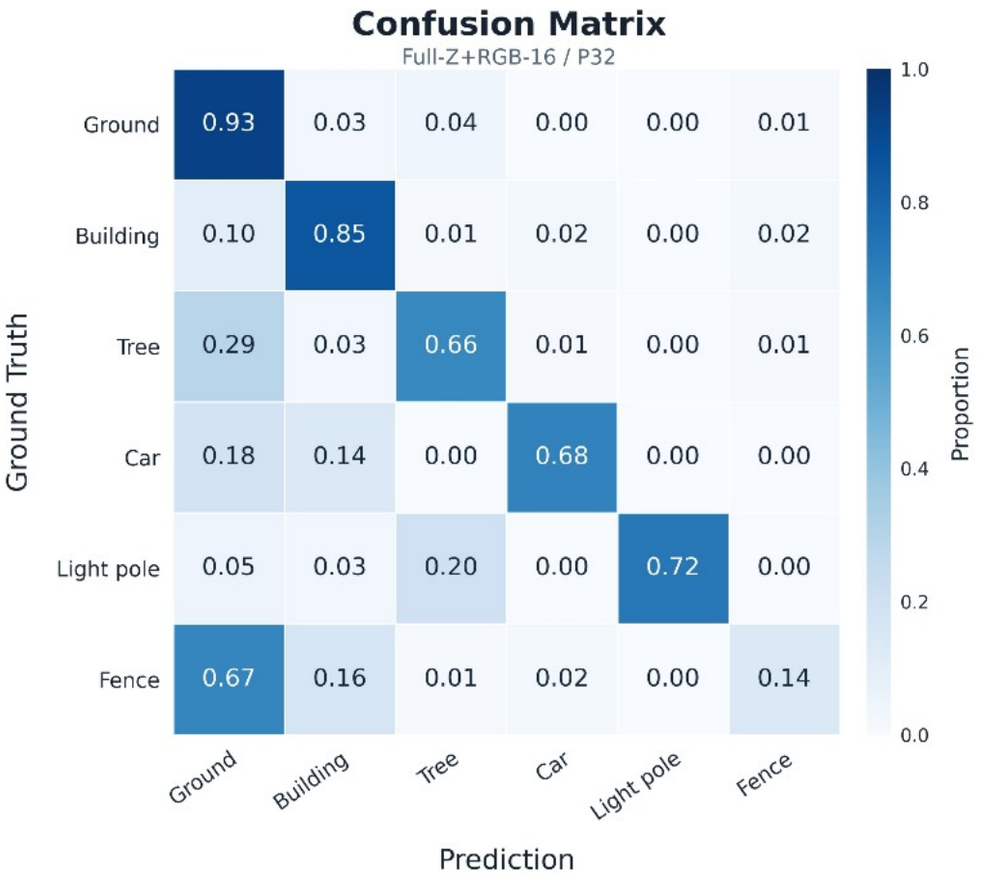
04. 실제 장면 평가 - 클래스별 분할 결과

Full-Z+RGB-16 / P32

클래스별 IoU (%)



Confusion Matrix



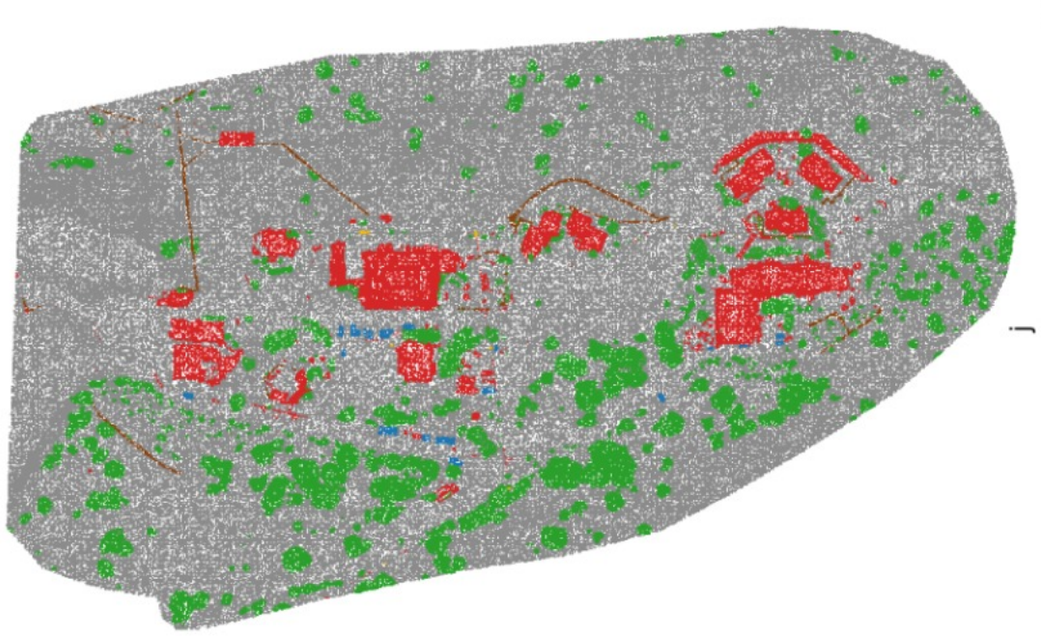
Fence IoU 7.0%, Recall 14%. 실제 Fence의 67%에서 Ground 오분류 발생

04. 실제 장면 평가 - 분할 결과 비교

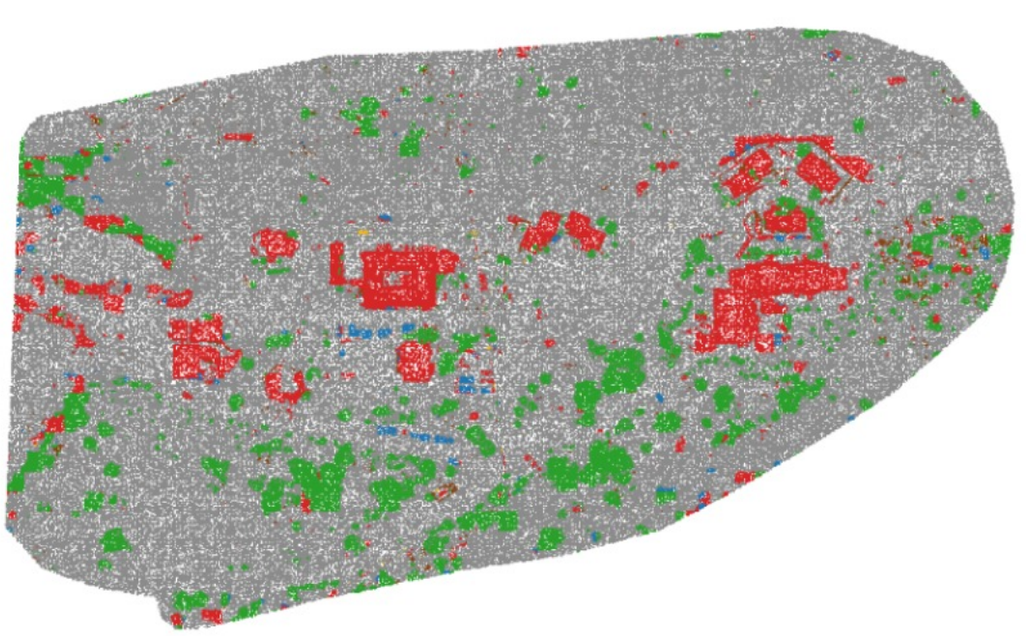
Full-Z+RGB-16 / P32

Ground Building Tree Car Light pole Fence

정답 라벨



예측 결과



Accuracy 85.34% mIoU 48.86% Macro F1 61.20%

05. 결론 및 후속 연구

복셀 학습 데이터의 색상·공간 구성에 따른 객체 분할 성능 차이 확인

Full-Z+RGB-16 / P32

mIoU **48.86%**

결과의 적용 범위

실제 평가는 WMSC 한 장면에 한정

Future Works

추가 실제 장면 평가 및 작은 객체의 오류 분석
실제 우리나라 데이터 분석

Q&A

감사합니다.